

Trabalho A2 - Series Temporais:

Resumo Executivo do Projeto

Gustavo Tironi, Kauan Mariani Ferreira, Livia Verly,
Matheus Filipe Ferreira de Carvalho, Pedro Henrique Coterli, Sillas Rocha da Costa

2 de dezembro de 2025

Introdução

Este relatório apresenta a segunda fase do projeto da disciplina de Séries Temporais, do curso de Ciência de Dados e Inteligência Artificial da Escola de Matemática Aplicada (EMAp) da Fundação Getulio Vargas (FGV) do Rio de Janeiro. Nessa etapa, evoluímos de uma análise simples para uma modelagem multivariada da variável `volume`. Agora, incorporamos dados de investimento (`inv`) e de usuários ativos (`users`) para verificar se essas informações externas melhoram a precisão das previsões em comparação aos modelos anteriores. O foco é entender o impacto real dessas variáveis de negócio, superando desafios estatísticos como relações não lineares e variações irregulares nos dados.

A metodologia baseou-se em identificar o tempo exato de impacto de cada variável (análise de lags) e aplicar transformações (logarítmicas) para ajustar a escala dos dados. O modelo final combina duas forças: uma parte estrutural (TSLM), que mede o efeito do marketing e usuários, e uma parte dinâmica (ARIMA com covariáveis), que corrige a inércia temporal da própria série. A validação foi feita simulando cenários reais de previsão semana a semana, com previsões sendo feitas para até 4 semanas a frente, garantindo que os resultados sejam confiáveis para uso prático.

1 Análise Exploratória Multivariada e Correlações

1.1 Visualização das séries

Nesta seção, realizaremos a análise exploratória dos dados com as variáveis `volume`, `inv` e `users`, a fim de identificar características que direcionem os modelos que serão ajustados.

Primeiramente, observemos o comportamento de cada série individualmente e em conjunto com suas versões normalizadas (cada série possui uma unidade de medida e uma escala diferentes).

Como podemos ver na Figura 1, parece haver uma relação forte entre as covariáveis `users` e `inv`, com ambas seguindo o mesmo padrão, principalmente nos picos ocorridos em 2022 e na metade de 2024. Por outro lado, nossa variável `target volume` ou não corresponde a isso ou corresponde de forma mais suave. Além disso, ao final da série, vemos uma força de crescimento muito maior nessa variável do que nas




Figura 1: Visualização das séries

outras.

1.2 Autocorrelação da variável target volume




Figura 2: ACF de volume




Figura 3: PACF de volume




Figura 4: Correlações entre a variável `volume` e as covariáveis, sem e com transformação logarítmica

Ao analisar o gráfico da ACF de `volume` na Figura 2, vemos uma persistência significativa nos primeiros lags, com um decaimento suave característico de séries não-estacionárias com forte componente de tendência, sugerindo que a inércia da própria série é um componente preditivo essencial. Isso indica antecipadamente que os modelos baseados apenas em covariáveis externos (como o TSLM simples, que será analisado na seção 2) provavelmente deixarão autocorrelação residual, exigindo uma abordagem de regressão dinâmica para capturar essa estrutura de memória.

Já o gráfico da PACF da target na Figura 3 confirma a estrutura auto-regressiva dessa variável, com um corte de significância abrupto após o lag 1, o que sugere um processo gerador AR de ordem 1. Esses resultados serão utilizados para o ajuste dos modelos ARIMA na seção 4.

1.3 Teste de sazonalidade

A decomposição STL revelou heterocedasticidade severa na série original, corrigida apenas após a transformação logarítmica. A componente sazonal mostrou-se irrelevante frente à tendência.

1.4 Correlações com as covariáveis

Em seguida, faremos gráficos de dispersão da variável target `volume` contra as covariáveis `inv` e `users`, tanto com a target original quanto com a versão transformada por log, para avaliar a significância das covariáveis para explicar a `volume`.

Pode-se ver na Figura 4 que ambas as variáveis possuem certa correlação com a variável target, indicando potencial preditivo. Entretanto, nas versões com a target original (linha superior), os pontos se distanciam consideravelmente da reta ajustada à medida que o valor das variáveis aumenta, indicando a presença de heterocedasticidade. Com isso, as versões com transformação logarítmica da `volume` apresentam uma correlação mais regular e significativa, mais uma vez reforçando a necessidade da utilização dessa transformação.

Além disso, os valores das covariáveis `inv` e `users` também aparentam ter uma distribuição assimétrica à direita,




Figura 5: CCF entre $\log(\text{volume})$ e as covariáveis

com uma grande concentração de pontos em valores baixos e uma escassez de registros com valores maiores. Isso sugere a aplicação de transformações logarítmicas também a essas covariáveis, o que será considerado no ajuste dos modelos TSLM na seção 2.

1.5 Correlação cruzada

Por fim, vamos analisar a correlação cruzada entre a variável `volume` já com transformação logarítmica e as covariáveis `inv` e `users`, com o objetivo de verificar o imediatismo do impacto dos valores dessas covariáveis na variável target ou a amplitude de seu lag.

Observando o lado direito dos gráficos da Figura 5, é possível ver que, tanto para `inv` quanto para `users`, existe uma alta correlação imediata entre elas e a `volume_log`, com valores significativos nos lags 0 e 1. No entanto, como não saberemos os valores dessas covariáveis na exata semana da qual queremos prever `volume`, então consideraremos aqui apenas o lag 1. Além disso, para a covariável `users`, podemos ver uma interação significativa entre ela e a variável target com 8 semanas de lag (2 meses), o que levanta a hipótese de um ciclo de maturação ou conversão tardia da base de usuários. Levaremos isso em consideração ao testar ajustes de modelos na próxima seção.

2 Modelagem TSLM

Ajustamos três especificações de modelos lineares para explicar o $\log(\text{volume})$: (1) simples (apenas covariáveis defasadas), (2) com tendência determinística e (3) elasticidade (log-log com tendência). Em todos os casos, utilizamos defasagens de $t - 1$ para viabilizar previsões futuras.

A comparação de métricas de ajuste demonstrou a clara superioridade do modelo de **elasticidade**, que apresentou o menor AIC (-122.15) e o maior R^2 ajustado (0.966), superando significativamente as versões lineares puras. A inclusão da tendência provou-se essencial (aumento de ≈ 0.45 no R^2 em relação ao modelo simples), e a transformação logarít-

Tabela 1: Coeficientes do modelo de elasticidade (final)

	coef	std err	t	P> t	[0.025	0.975]
const	-0.3996	0.033	-11.971	0.000	-0.466	-0.334
trend	0.0155	0.000	37.616	0.000	0.015	0.016
log_inv	0.4035	0.074	5.436	0.000	0.257	0.550
log_users	0.0626	0.035	1.771	0.079	-0.007	0.133
users_log_lag_8	0.1811	0.020	9.015	0.000	0.141	0.221

mica das covariáveis capturou melhor a não-linearidade dos dados.

2.1 Modelo selecionado e significância

Com base na performance superior, selecionamos o modelo de Elasticidade para as etapas seguintes. A Tabela 1 detalha os coeficientes estimados.

A análise revela que quase todos os regressores são estatisticamente significativos, confirmando a relevância da tendência e dos lags de investimento e usuários. A exceção é a variável `log_users`, que apresenta p-valor no limite da significância (0.079).

Realizamos testes de filtragem comparando este modelo completo contra uma versão reduzida (sem `log_users`). A remoção da variável resultou em uma leve piora no coeficiente AIC (de -122.15 para -120.94) e no R^2 ajustado. Portanto, optamos por manter a covariável no modelo final, priorizando a capacidade informativa e o critério de Akaike.

3 Diagnóstico de resíduos

Em seguida, realizamos o diagnóstico do modelo de elasticidade selecionado para verificar as premissas de normalidade, homocedasticidade e independência temporal.




Figura 6: Distribuição dos resíduos




Figura 7: ACF dos resíduos

A análise visual da distribuição na Figura 6 sugere um comportamento gaussiano, hipótese confirmada pelo teste de Jarque-Bera, que apresentou p-valor de **0.2790**. Não há evidências estatísticas para rejeitar a normalidade dos resíduos.

Diferente da normalidade, a premissa de independência foi violada. O gráfico de ACF na Figura 7 exibe correlação sig-

nificativa no lag 1. O teste de Ljung-Box corroborou este diagnóstico, apresentando p-valores < 0.05 para todos os 10 primeiros lags. Isso confirma que o modelo TSLM estrutural falhou em capturar a dinâmica inercial da série.




Figura 8: Resíduos vs. covariáveis transformadas

Por fim, a inspeção visual dos resíduos contra as covariáveis na Figura 8 mostra dispersão aleatória e ausência de padrões, validando a forma funcional log-log. O erro do modelo não está correlacionado com o nível de investimento ou usuários.

Portanto, o diagnóstico aponta que o modelo TSLM satisfaz as premissas de normalidade e de forma funcional correta (resíduos independentes das covariáveis). No entanto, a premissa de independência temporal falha. Portanto, para obter um modelo robusto e previsões confiáveis, é imperativo modelar essa autocorrelação residual utilizando a metodologia ARIMA na próxima etapa.

4 Modelagem de regressão dinâmica (ARIMA)

Dada a falha no pressuposto de independência observada na seção anterior, a abordagem estrutural do TSLM mostrou-se insuficiente para capturar toda a dinâmica da série. Para corrigir isso, faremos a seguir a modelagem de regressão dinâmica, onde a estrutura de correlação dos erros é explicitamente modelada por um processo ARIMA.

Para isso, mantivemos as covariáveis transformadas (elasticidade e tendência) como a parte determinística do modelo, mas permitimos que o termo de erro seguisse um processo estocástico dependente do tempo. A análise dos resíduos do TSLM indicaram que uma componente auto-regressiva seria necessário para capturar a inércia restante.

4.1 Modelo Selecionado: ARIMA(1,0,0)

Após comparar diferentes especificações e verificar os critérios de informação (AIC e BIC), o melhor modelo encontrado foi o **ARIMA(1, 0, 0)** aplicado sobre as variáveis em logaritmo, como mostrado na tabela 2.

Isso significa que o erro no tempo t é explicado parcialmente pelo erro no tempo $t - 1$ (ϕ_1). Essa estrutura corrige a autocorrelação de lag 1 que havia sido detectada no diagnóstico do TSLM. A equação do modelo final assume a forma híbrida:

Tabela 2: Comparação dos critérios de informação (AIC e BIC) dos modelos ARIMA

Modelo	Transformação	AIC	BIC
ARIMA(1, 0, 0)	Log-log	-161.431	-146.411
ARIMA(1, 1, 0)	Log-log	-159.272	-144.253
ARIMA(1, 0, 0)	Originais	-158.283	-143.264
ARIMA(1, 1, 0)	Originais	-156.025	-141.006
ARIMA(1, 1, 1)	Log-log	-144.516	-126.492
ARIMA(0, 1, 1)	Log-log	-144.475	-129.456
ARIMA(0, 1, 1)	Originais	-139.211	-124.191
ARIMA(1, 1, 1)	Originais	-138.624	-120.600

$$\log(Y_t) = \underbrace{\beta_0 + \beta X_{t-1}}_{\text{Estrutural}} + \eta_t$$

$$\eta_t = \phi_1 \eta_{t-1} + \varepsilon_t$$

4.2 Comparação de performance

O modelo ARIMA(1, 0, 0) log-log demonstrou capacidade superior em capturar a dinâmica de curto prazo da série, transformando os resíduos finais em ruído branco (sem autocorrelação significativa), como mostrado na Figura 9. Com isso, temos um modelo que combina interpretação econômica clara (através das elasticidades das covariáveis) com robustez estatística, estando pronto para a fase de previsão e avaliação de performance.




Figura 9: Análises de resíduos do modelo ARIMA

5 Previsão e avaliação de performance

Nesta etapa final, avaliamos a capacidade preditiva dos modelos em um cenário de produção simulado. Utilizamos uma estratégia de janelas deslizantes (*rolling forecast*), onde os modelos foram re-treinados semanalmente para projetar o volume para as 4 semanas seguintes.

5.1 Comparação de modelos

Para validar a robustez da nossa abordagem híbrida, comparamos a performance do modelo final (ARIMA com covariáveis) contra dois *baselines*:

- **Naive:** Modelo ingênuo que projeta o último valor observado. Serve como referência mínima de performance.
- **TSLM (linear):** O modelo de regressão linear ajustado na Seção 2, que considera apenas as variáveis explicativas sem correção dinâmica.
- **ARIMA (dinâmico):** O modelo final selecionado na Seção 4, que une as variáveis explicativas à correção auto-regressiva.

A Tabela 3 apresenta as métricas de erro calculadas no conjunto de teste.

Tabela 3: Comparação das métricas de avaliação por modelo e horizonte

Modelo	Horizon	RMSE	MAE
Naive Baseline	1	1.355063	0.903774
ARIMAX(1, 0, 0)	1	1.403623	0.916456
Naive Baseline	2	1.771870	1.252547
TSLM (Log-Log)	1	1.801597	1.134827
ARIMAX(1, 0, 0)	2	1.898763	1.346283
TSLM (Log-Log)	2	1.905809	1.239287
Naive Baseline	3	2.022270	1.477264
TSLM (Log-Log)	3	2.112658	1.341630
Naive Baseline	4	2.123585	1.501509
ARIMAX(1, 0, 0)	3	2.180127	1.599594
TSLM (Log-Log)	4	2.182385	1.495324
ARIMAX(1, 0, 0)	4	2.340514	1.698891

Ao analisar os resultados, observamos que o modelo **Naive Baseline** apresentou consistentemente o melhor desempenho global, superando tanto o **TSLM** quanto o **ARIMAX** em todos os horizontes de previsão avaliados (menores RMSE e MAE).

Embora as variáveis de negócio (*inv* e *users*) tenham mostrado relevância estatística na etapa de ajuste (in-sample), elas não se traduziram em ganho preditivo no cenário de teste (out-of-sample). Esse resultado sugere que a série do volume possui uma dinâmica fortemente inercial (comportamento próximo a um *Random Walk*), onde a informação mais recente da própria variável (Y_{t-1}) é o preditor mais robusto para o curto prazo. A complexidade adicional trazida pelos modelos multivariados acabou introduzindo ruído ou overfitting, sem conseguir capturar variações futuras melhor do que a simples persistência do último valor observado.

5.2 Previsão final (rolling forecast)

A Figura 10 apresenta o comparativo visual entre o volume previsto pelo melhor modelo (Naive) e o volume real observado.




Figura 10: Previsões 1-Passo à Frente vs Real - Naive Base-line

O gráfico confirma a alta aderência do modelo ingênuo aos dados reais. O modelo consegue acompanhar as oscilações e a tendência geral de crescimento da série com um atraso de apenas um período (característico do Naive), mantendo um erro controlado. Isso valida a utilização do baseline para o planejamento operacional de curtíssimo prazo, dada a dificuldade dos modelos estruturais em antecipar as mudanças de direção da série com precisão superior.

Conclusão

A tabela de desempenho (Tabela 3) resume a performance dos modelos (Naive, ARIMAX e TSLM) através de múltiplos horizontes de previsão (1 a 4 semanas). A análise conjunta das métricas de erro pontual (RMSE, MAE) e probabilístico (Winkler Score, CRPS) revela a superioridade das abordagens inerciais para fins de *forecasting*.

Performance em Erro Pontual (RMSE)

O **Naive Baseline** dominou a performance em todos os horizontes temporais, apresentando consistentemente o menor RMSE.

- **Curto prazo (horizonte 1):** O Naive atingiu um RMSE de 1.35, seguido de perto pelo ARIMAX (1.40). O TSLM, mesmo com variáveis explicativas, iniciou com um erro significativamente maior (1.80).
- **Degradação temporal:** Como esperado, o erro aumenta conforme o horizonte se expande. No entanto, a degradação do Naive é controlada, terminando o Horizonte 4 com RMSE de 2.12, ainda superior ao TSLM (2.18) e ao ARIMAX (2.34).
- **Nota sobre o ARIMAX:** Embora competitivo no curto prazo ($h = 1$), o ARIMAX degrada mais rapidamente que os demais, tornando-se o pior modelo em acurácia pontual no horizonte 4.

Um dos achados mais impactantes deste estudo encontra-se na comparação entre modelos de diferentes complexidades:

O RMSE do TSLM prevendo apenas 1 passo à frente (1.80) foi superior (pior) ao do Naive prevendo 2 passos à frente (1.77).

Isso evidencia que a tentativa de modelar a estrutura causal da série (Investimento e Usuários) introduziu mais variância e ruído do que apenas assumir a inércia de duas semanas atrás. Isso ocorre provavelmente devido à dificuldade de estimar com precisão os valores futuros das variáveis exógenas (*input error*).

Análise de Incerteza e Risco (Winkler Score)

A análise do **Winkler Score** (que penaliza intervalos de confiança largos ou imprecisos) **desqualifica o TSLM** para uso em gestão de risco.

- **Robustez do Naive/ARIMAX:** Ambos apresentaram Winkler Scores baixos e estáveis (entre 6.0 e 12.0), indicando que seus intervalos de confiança são úteis e bem calibrados.
- **Instabilidade do TSLM:** O TSLM apresentou Winkler Scores exorbitantes, variando de 31.1 a 43.7.
 - *Diagnóstico:* A transformação Log-Log, ao ser revertida, provavelmente explodiu os intervalos de confiança. Isso torna o TSLM perigoso para definir estoques de segurança ou planejar limites operacionais, pois ele superestima drasticamente a incerteza.

Os dados confirmam que a série possui um comportamento próximo ao de um **Passeio Aleatório (Random Walk)**, onde a informação do último período é a melhor estimativa para o próximo.